

Web Scraper

Let's Gooo →

PRISE EN MAIN



1- TELECHARGER L'EXTENSION

chrome web store

Search extensions and themes

Discover Extensions Themes




Web Scraper - Free Web Scraping

Remove from Chrome

[webscraper.io](#) **Featured** 4.0 ★ (881 ratings)

Extension Workflow & Planning 700,000 users



WEBCRAPER


Avantage :

- le coût (freemium)
- la quantité de données (plusieurs cas d'usage)



2 - INSPECTER (F12 OU CMD+OPT+C)

Manipulation pour accéder à Webscraper :
Clic droit → Inspecter



3 - CRÉER UN SITEMAP - ETAPE 1

DevTools is now available in French! [Always match Chrome's language](#) [Switch DevTools to French](#) [Don't show again](#)

Elements

Console

Recorder

Sources

Network

Performance insights

Performance

Memory

Application

Security

Lighthouse

Web Scraper

52

4

Sitemaps

Sitemap

Create new sitemap

Sign in to Cloud

Search Sitemaps

Create Sitemap

Import Sitemap


ID	Domain	
scrap_etudiant	letudiant.fr	Delete
scraping_usine_digital	usine-digitale.fr	Delete

Console

What's new

Issues

3 - CRÉER UN SITEMAP - ETAPE 2



3 - S T R U C T U R E D E P A G E

L'objectif va être de créer une séquence d'automatisation dans les pages web afin de récupérer la data

Sitemaps Sitemap spectable ▾ Create new sitemap ▾

_root

Data preview

	ID	Selector	type	Multiple	Parent selectors	Actions
Add new selector						

⋮

Console What's new × Issues

×

3 - STRUCTURE DE PAGE - SUITE 1

Sitemaps

Sitemap spectable ▼

Create new sitemap ▼

Id

Selector Id

→ le nom de la sélection

Type

Text

→ voir page suivante

Selector

Select

Element preview

Data preview

→
Select : Permet de sélectionner la zone à utiliser ou scraper
Element preview : Permet de voir la zone sélectionnée
Data Preview : Permet de voir les data scraper

☐ Multiple

Parent Selectors

_root

Save selector

Cancel

3 - STRUCTURE DE PAGE - SUITE 2

Sitemaps

Sitemap test-resalib ▾

Create new sitemap ▾

Help ▾

Id

Type

Selector

Multiple Type

Parent Selectors

Selector Id

✓ Text

Link

Image

Table

Element attribute

HTML

Element (scroll)

Element click

Sitemap.xml Links

Pagination

Quel type de data vous allez récolter ?

Ex : Du texte, un lien, un tableau, une image ...

4 - LES CONFIGURATIONS GLOBALES

The screenshot shows the 'Sitemaps' interface. At the top, there are three tabs: 'Sitemaps', 'Sitemap spectable' (which is active), and 'Create new sitemap'. Below the tabs, there is a sidebar on the left with a tree view showing a hierarchy: '_root' (selected) and 'base' (indicated by a hamburger menu icon). Below the sidebar is a button labeled 'Add new selector'. The main area displays a dropdown menu for the 'Sitemap spectable' tab. The menu items and their corresponding actions are:

Action	Description
Selectors	Retour à la configuration
Edit metadata	Changer le site et le nom
Website state setup	selector
Scrape	Scraper la/les page(s)
Browse	Permet de revenir sur votre scraping
Export Sitemap	Exporter le sitemap
Export data	Exporter le fichier en .xls ou .csv

5 - CRÉATION DU SITEMAP - ETAPE 1

Les événements clés :

Done selecting -> Valide la selection

P-> Sélectionne les éléments parents (Parent)

C -> Sélectionne les éléments enfants (Child)

S -> Sauver votre selection

En activant les événements clés, vous pouvez sélectionner des éléments en les survolant avec la souris et en appuyant sur la touche « S ».

La touche « C » ne fonctionne que si la touche « P » a été utilisée auparavant.



Exemple

Connecte toi à ce lien :

https://www.spectable.com/narbonne-11100/l_2142.php



ETAPE 1- JE REGARDE LA STRUCTURE DE LA PAGE

On constate qu'il y a deux choses :

1 - les fiches qui renvoient vers des liens

2 - la pagination

(elle s'affiche que si l'ont rafraichi la page)



LUZ DO BRASIL - Musique brésilienne - Jazz brésilien

Narbonne (11100)

Laissez-vous envoûter par la douce ambiance d'un répertoire lumineux ; vous allez pouvoir profiter des couleurs de la Bossa Nova, apparue dans les années 50 et développée par des musiciens tels que Tom Jobim, Chico ...



Sunflower groupe

Narbonne (11100)

Bonjour, Vous cherchez un groupe pour animer un mariage, une réception, une soirée? Nous sommes SUNFLOWER, un duo guitare- voix, et nous possédons un large répertoire de musiques dansantes et d'ambiance. Nous ...



Cours de musique, chant, éveil musical

Narbonne (11100)

ABC MUSIC <<< APPRENDRE LA MUSIQUE AUTREMENT Ecole de musique associative Cours de guitare / piano / violon / synthé / M.A.O. / chant / éveil musical

Depuis 2004 Spectacle est alimenté par la communauté artistique de votre région.
Rejoignez la!



Passez gratuitement votre annonce

2 - CRÉATION DU SITEMAP - ETAPE 1

La marche à suivre :

1 -> Créer le sitemap

2 - “Add new selector” ->Type : pagination

3 - Selector : Select

4 - Sélectionner le chevront (voir photo)

5 - “Done Selecting”

6 - Save selector

Id

page

Type

Pagination

Selector

SelectElement previewData previewa.next_page

Pagination type

auto

Parent Selectors


_root

lien

page

Save selector

Cancel



a.next_page

P

C

S

Done selecting

Prochaine étape cliquer/rentrer dans “la page”

SitemapsSitemap Spectable_nabonneCreate new sitemapHelp

_root

ID	Selector
page	a.next_page

Add new selector

Generate Selectors with AI (Alpha): Listing page

1 - “Add new selector” → Type : Link

2 - Selector : Select

3 - Cliquer sur les 2 premiers lien, le reste va suivre

4 - “Done Selecting”

5 - Save selector

Id

lien

Type

Link

Selector

SelectElement previewData preview.acc a

Link type

☒ MultipleLink (read from href attribute)

Parent Selectors

_root

lien

page

Save selector

Cancel



.acc a

P

C

S

Done selecting

2 - CREATION DU SITE MAP - ETAPE 2

SPECTACLE

Mots clefs

Ville

Chercher

Déposer une annonceMon compte

Artistes & CréationsNarbonne

Musique : Jazz , Blues - Traditionnelle, du monde

fPartager

tTwitter

LUZ DO BRASIL - Musique brésilienne - Jazz brésilien

Narbonne (11100)

Laissez-vous envoûter par la douce ambiance d'un répertoire lumineux ; vous allez pouvoir profiter des couleurs de la Bossa Nova, apparue dans les années 50 et développée par des musiciens tels que Tom Jobim, Chico Buarque ou encore Joao Gilberto, et glisser vers les rythmes plus soutenus de la Samba, dont le « Balancé » nous emmène au pays du soleil, de la fête, de la sensualité et de la joie de vivre. Luz do Brasil interprète la musique brésilienne moderne : Des grands classiques, comme le fameux « Berimbau » de l'illustre Baden Powell, immortalisé en France par Claude Nougaro et son « Bidonville », ou encore ce superbe « Carinhoso » écrit en 1937 par Pixinguinha, l'un des compositeurs les plus respectés au Brésil, aux musiques plus modernes comme « Madalena », issue du génie de Ivan Lins, ou encore « Flor de Lis », de Djavan, chanson adulée par les brésiliens. Émaillée d'anecdotes sur l'histoire de cette musique, ce répertoire nous parle d'amour, de joie, de tristesse et de la fameuse saudade, cette nostalgie si particulière au peuple brésilien.

Luz Do Brasil, c'est aussi l'histoire d'une rencontre.

Quatre musiciens talentueux qui se sont retrouvés autour de la richesse de cette musique.

Ecrire à l'auteur de l'annonce

Contact
Corinne 06.86.90.84.49

Sur le net
https://www.youtube.com/watch?v=yTk_Pnnn3_w

Centre Musical C.B. - Cours de Batterie ludiques
Centre Musical Christian Bouquet
Narbonne (11100)

Centre Musical C.Bouquet Inscriptions 22/23
Narbonne (11100)

Spectacles de variétés féériques chantés en direct
Minipiscinet (11120)

Éléments

Console

Enregistreur

Sources

Réseau

Performances

Mémoire

Appli

Sécurité

Lighthouse

Web Scraper

Sitemaps

Sitemap Spectacle_narbonne

Create new sitemap

Help

_root / page / lien

Data preview

ID	Selector	type	Multiple	Parent selectors	Actions
nom	h1	SelectorText	no	lien	<button>Element preview</button> <button>Data preview</button> <button>Edit</button> <button>Delete</button>
description	#a > p:nth-of-type(1)	SelectorText	no	lien	<button>Element preview</button> <button>Data preview</button> <button>Edit</button> <button>Delete</button>
tel	p:nth-of-type(2)	SelectorText	no	lien	<button>Element preview</button> <button>Data preview</button> <button>Edit</button> <button>Delete</button>
site	.p0 a	SelectorText	no	lien	<button>Element preview</button> <button>Data preview</button> <button>Edit</button> <button>Delete</button>

Add new selector

Generate Selectors with AI (Alpha):

Listing page

Single item page

Maintenant je récupère les informations à l'intérieur de la fiche :

1 -> Je clique sur la 1er fiche

2 -> Je click sur l'ID : Lien

3 -> Je crée un nouveau sélecteur (Add new selector)

4 -> Je récupère les données qui m'intéressent via les selecteurs textes

2 - CRÉATION DU SITEMAP - ETAPE 3

- La marche à suivre :
- 1 - “Add new selector” ->Type : Text
 - 2 - Selector : Select
 - 3 - Sélectionner le text à récupérer
 - 4 - “Done Selecting”
 - 5 - “Save selector”
- Et on recommence l’opération

Id

nom

Type

Text

Selector

Select

Element preview

Data preview

h1

Multiple Type

First Record Only

Parent Selectors

_root

lien

page

Save selector

Cancel

Contact

Corinne 06.86.90.84.49

Sur le net

https://www.youtube.com/watch?v=yTk_Pnnn3_w

<aside id="blk_laune">

p:nth-of-type(2)

P

C

S

Done selecting

Centre Musical C.B. - Cours de Batterie ludiques

Centre Musical Christian Bouquet

Narbonne (11100)

Centre Musical Christian Bouquet

Faire naître le talent

Centre

Éléments

Console

Enregistreur

Sources

Réseau

Performances

Mémoire

Appli

Sécurité

Lighthouse

Web Scraper

Sitemaps

Sitemap Spectacle_nabonne

Create new sitemap

Help

Id

nom

Type

Text

Selector

Select

Element preview

Data preview

h1

Multiple Type

First Record Only

Parent Selectors

_root

lien

page

Save selector

Cancel

3 - L E S C R A P E

Sitemaps

Sitemap Spectable ▼

Create new sitemap ▼

_root / base /

	ID
≡	Nom
≡	tel
≡	adresse
≡	Code postal
≡	resume

Selectors

Edit metadata

Website state setup

Scrape

Browse

Export Sitemap

Export data

	Selector
	h1
	p:nth-of-type(2)
	#a span
	header b
	#a > p:nth-of-type(1)

Une page va alors s'ouvrir pour commencer la récupération des data

Sitemaps

Sitemap Spectable ▼

Create new sitemap ▼

Request interval (ms)


2000

Page load delay (ms)

2000

Start scraping

4 - TELECHARGER LES DONNEES



5 - IMPORTER UN SITEMAP

Sitemaps

Sitemap ▾

Create new sitemap ▾

Search Sitemaps

ID

Create Sitemap

Import Sitemap

Sitemaps

Sitemap ▾

Create new sitemap ▾

Sitemap JSON 1

Copier le code ici

Sitemap name 2

Sitemap name

Donner lui un nom

3

Import Sitemap

```
{ "_ID": "SPECTABLE_NABONNE", "STARTURL": [ "HTTPS://WWW.SPECTABLE.COM/NARBONNE-11100/L_2142.PHP" ], "SELECTORS":
  [ { "ID": "LIEN", "PARENTSELECTORS": [ "PAGE" ], "TYPE": "SELECTORLINK", "SELECTOR": ".ACC
    A", "MULTIPLE": true, "VERSION": 2, "LINKTYPE": "LINKFROMHREF" }, { "ID": "NOM", "PARENTSELECTORS":
[ "LIEN" ], "TYPE": "SELECTORTEXT", "SELECTOR": "H1", "MULTIPLE": false, "REGEX": "", "MULTIPLYTYPE": "SINGLECOLUMN", "VERSION": 2 },
  { "ID": "DESCRIPTION", "PARENTSELECTORS": [ "LIEN" ], "TYPE": "SELECTORTEXT", "SELECTOR": "#A > P:NTH-OF-
    TYPE(1)", "MULTIPLE": false, "REGEX": "", "MULTIPLYTYPE": "SINGLECOLUMN", "VERSION": 2 }, { "ID": "TEL", "PARENTSELECTORS":
[ "LIEN" ], "TYPE": "SELECTORTEXT", "SELECTOR": "P:NTH-OF-
    TYPE(2)", "MULTIPLE": false, "REGEX": "", "MULTIPLYTYPE": "SINGLECOLUMN", "VERSION": 2 }, { "ID": "SITE", "PARENTSELECTORS":
[ "LIEN" ], "TYPE": "SELECTORTEXT", "SELECTOR": ".PO A", "MULTIPLE": false, "REGEX": "", "MULTIPLYTYPE": "SINGLECOLUMN", "VERSION": 2 },
  { "ID": "PAGE", "PARENTSELECTORS":
[ "_ROOT", "PAGE" ], "PAGINATIONTYPE": "AUTO", "TYPE": "SELECTORPAGINATION", "SELECTOR": "A.NEXT_PAGE" } ] }
```

<https://www.loom.com/share/ba72f1a6e2db4653a8322a1c6634ac6b>



SPECTABLE

EXERCICE

Scraper les infos des salles de spectacle à Narbonne :

https://www.spectable.com/narbonne-11100/l_2142.php

Informations demandées (toutes les fiches) :

- NOM D'ENTREPRISE
- PRENOM
- NOM
- ADRESSE
- CODE POSTAL
- NUMÉRO DE TÉL
- SITE WEB



SPECTABLE

CORRECTION
EXERCICE

```
{ "_id": "Spectable_nabonne", "startUrl": ["https://www.spectable.com/narbonne-11100/l_2142.php"], "selectors": [{ "id": "lien", "linkType": "linkFromHref", "multiple": true, "parentSelectors": ["page"], "selector": ".acc a", "type": "SelectorLink", "version": 2 }, { "id": "nom", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "h1", "type": "SelectorText", "version": 2 }, { "id": "description", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "#a > p:nth-of-type(1)", "type": "SelectorText", "version": 2 }, { "id": "tel", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "p:nth-of-type(2)", "type": "SelectorText", "version": 2 }, { "id": "site", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": ".p0 a", "type": "SelectorText", "version": 2 }, { "id": "page", "paginationType": "auto", "parentSelectors": ["_root", "page"], "selector": "a.next_page", "type": "SelectorPagination" } ] }
```

Scraper les infos des experts comptables de Neuilly-Sur-Seine :

<https://annuaire.experts-comptables.org/recherche/ville/neuilly-sur-seine?seed=88980>

Informations demandées (toutes les fiches) :

- NOM D'ENTREPRISE
- PRENOM
- NOM
- ADRESSE
- NUMÉRO DE TÉL

```
{ "_id": "ODEC-OK", "startUrl": ["https://annuaire.experts-comptables.org/recherche/ville/neuilly-sur-seine/[1-2]"], "selectors":  
[ { "id": "lien", "linkType": "linkFromHref", "multiple": true, "parentSelectors": [ "_root" ], "selector": "div.name  
a", "type": "SelectorLink", "version": 2 }, { "id": "contacts", "multiple": false, "multipleType": "singleColumn", "parentSelectors":  
[ "lien" ], "regex": "", "selector": "div.row", "type": "SelectorText", "version": 2 },  
{ "id": "adresse", "multiple": false, "multipleType": "singleColumn", "parentSelectors": [ "lien" ], "regex": "", "selector": ".mb-3  
strong", "type": "SelectorText", "version": 2 }, { "id": "nom cab", "multiple": false, "multipleType": "singleColumn", "parentSelectors":  
[ "lien" ], "regex": "", "selector": "h1", "type": "SelectorText", "version": 2 }, { "clickActionType": "real", "clickElementSelector": "div.firm-  
phone", "clickElementUniquenessType": "uniqueText", "clickType": "clickOnce", "delay": 2000, "discardInitialElements": "do-not-  
discard", "id": "autom", "multiple": true, "parentSelectors": [ "lien" ], "selector": "a.phone-link", "type": "SelectorElementClick" },  
{ "id": "tel", "multiple": false, "multipleType": "singleColumn", "parentSelectors":  
[ "autom" ], "regex": "", "selector": "_parent_", "type": "SelectorText", "version": 2 } ] }
```


<https://www.loom.com/share/1a5d7f2af9df402d91f2621adb5d57a5>



E X E R C I C E

Scraper les infos des pawnshops de Los Angeles – USA

<https://www.pawnshops.net/>

Informations demandées (toutes les fiches) :

- NOM D'ENTREPRISE
- ADRESSE
- MAIL
- NUMÉRO DE TÉL
- RESEAUX SOCIAUX (YELP, FACEBOOK, TWITTER, INSTAGRAM)



CORRECTION EXERCICE

pawnshop

```
{ "_id": "pawnshops-OK", "startUrl": ["https://www.pawnshops.net/search.php?whatcountry=US&whatstate=CA&whatcity=Los+Angeles"], "selectors": [{"id": "page", "paginationType": "auto", "parentSelectors": ["_root", "page"], "selector": "li:nth-of-type(5) a.col-xs-12", "type": "SelectorPagination"}, {"id": "lien", "linkType": "linkFromHref", "multiple": true, "parentSelectors": ["page"], "selector": "h4 a", "type": "SelectorLink", "version": 2}, {"id": "social", "linkType": "linkFromHref", "multiple": false, "parentSelectors": ["lien"], "selector": "a.social", "type": "SelectorLink", "version": 2}, {"id": "adresse", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "[itemprop='address'] p", "type": "SelectorText", "version": 2}, {"id": "ville", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "span[itemprop='addressLocality']", "type": "SelectorText", "version": 2}, {"id": "tel", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "regex": "", "selector": "a.tel-links", "type": "SelectorText", "version": 2}, {"extractAttribute": "href", "id": "mail", "multiple": false, "multipleType": "singleColumn", "parentSelectors": ["lien"], "selector": "_parent_", "type": "SelectorElementAttribute", "version": 2} ] }
```



CORRECTION
EXERCICE



BIEN PENSER À PRENDRE LE LIEN

Id

links

Type

Link

Selector

Select

Element preview

Data preview

h4 a

Link type

☒ Multiple

Link type

Link (read from href attribute)

Parent Selectors

_root

links

yelp

Save selector

Cancel

_root						Data preview
ID	Selector	type	Multiple	Parent selectors	Actions	
links	h4 a	SelectorLink	yes	_root	Element preview	Data preview Edit Delete



ALTERNATIVE POUR LA PAGINATION

Sitemaps

Sitemap a132-pawnshop

Create new sitemap

Sitemap name

a132-pawnshop

Start URL 1

https://www.pawnshops.net/search.php?whatcountry=US&whatstate=CA&whatcity=Los+Angeles&s=[1-7]

Save Sitemap



EMAIL ET LIEN

email	div.col-md-12:nth-of-type(4) p	SelectorHTML	no	links
yelp	a.social	SelectorLink	no	links



VIDEO EXERCISE

<https://www.loom.com/share/1a5d7f2af9df402d91f2621adb5d57a5>



EXERCICE 4

Scraper les infos des praticiens de Rennes :

<https://www.resalib.fr/rechercher>

Informations demandées (2 premières pages) :

- Réseaux sociaux (facebook, linkedin, instagram, twitter)
- Numéro de tél
- Adresse postale
- SIRET
- Date de début d'activité
- Nom Prénom



CORRECTION EXERCICE 4

resalib

```
{ "_id": "test-resalib", "startUrl": [ "https://www.resalib.fr/rechercher?&location=Rennes&latitude=48.117266&longitude=-1.6777926&offset=[0-1]" ], "selectors": [ { "id": "base", "linkType": "linkFromHref", "multiple": true, "parentSelectors": [ "_root" ], "selector": ".featured-title-box > a:nth-of-type(1)", "type": "SelectorLink" }, { "id": "Reso", "linkType": "linkFromHref", "multiple": true, "parentSelectors": [ "base" ], "selector": "a.linkSocial", "type": "SelectorLink" }, { "id": "adresse", "multiple": false, "multipleType": "singleColumn", "parentSelectors": [ "base" ], "regex": "", "selector": ".adressmap p", "type": "SelectorText" }, { "id": "siretxt", "multiple": false, "multipleType": "singleColumn", "parentSelectors": [ "base" ], "regex": "", "selector": "p.m-0:nth-of-type(1) a", "type": "SelectorText" }, { "id": "pappers", "linkType": "linkFromHref", "multiple": false, "parentSelectors": [ "base" ], "selector": "p.m-0:nth-of-type(1) a", "type": "SelectorLink" }, { "id": "crea", "multiple": false, "multipleType": "singleColumn", "parentSelectors": [ "pappers" ], "regex": "", "selector": "th:contains('Création:') + td", "type": "SelectorText" }, { "clickActionType": "real", "clickElementSelector": "a#showPhone", "clickElementUniquenessType": "uniqueText", "clickType": "clickOnce", "delay": 2000, "discardInitialElements": "do-not-discard", "id": "numero-tel", "multiple": true, "parentSelectors": [ "base" ], "selector": ".linkPhone a", "type": "SelectorElementClick" }, { "id": "numerotel", "multiple": false, "multipleType": "singleColumn", "parentSelectors": [ "base" ], "regex": "", "selector": ".linkPhone a", "type": "SelectorText", "version": 2 } ] }
```

<https://www.loom.com/share/25f00043a0984b9c8ce53cd58cc67fed>